

Homework

Final Project - Stage 2



1. Data Pre-Processing

Rakamin

A. Data Splitting

```
# split train and test set

# memisahkan antara training dan test set

from sklearn.model_selection import train_test_split

data_train, data_test = train_test_split(data, test_size=0.2, random_state=42)

# menampilkan shape dari train dan test set

print(f'data_train: {data_train.shape}, data_test: {data_test.shape}')

data_train: (1792, 26), data_test: (448, 26)
```

Setelah dilakukan data split maka data kita telah memiliki partisi untuk test dan training dimana data_train 1792 sample dengan 26 feature dan data_test 448 sample dengan 26 feature juga.

1. Data Pre-Processing

B. Handling Missing Values

Pada data_train Terdapat 19 missing values (1.06%) dimensi sebelum (1792, 26) setelah Drop missing values – dimensi sesudah (1773, 26)

Pada data_test Terdapat 5 missing values (1.12%) dimensi sebelum (448, 26) setelah Drop missing values dimensi sesudah (443, 26)

C. Handling Duplicate Values

Pada data_train Terdapat 116 duplicate values (6.54%) dimensi sebelum (1773, 26) setelah Drop duplicate values – dimensi sesudah (1657,26)

Pada data_test Terdapat 6 duplicate values (1.35%) dimensi sebelum (443, 26) setelah Drop missing values dimensi sesudah (437, 26)



```
Data Train Shape: (1792, 26)
Data Test Shape: (448, 26)
#1.Identification Missing Values
column missing values percentage
Income
```

1. Data Pre-Processing



D. Handling Outliers

Menggunakan Z-Score threshold std = 3, pada column Income dan Year_Birth

Column Income

Before 1657.00

After 1650.00

Outliers 7.00

% Outliers 0.42

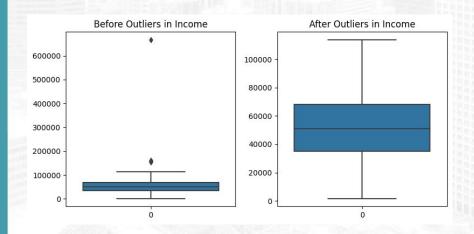
Column Year_Birth

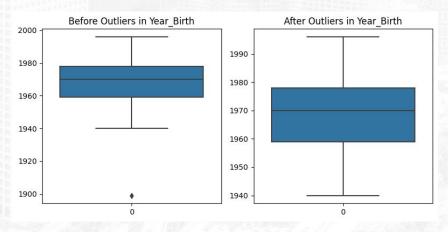
Before 1650.00

After 1649.00

Outliers 1.00

% Outliers 0.06





Rakamin

A. Feature Extractions

```
marital = {
        'Single': 'Not in relationship'.
        'Divorced': 'Not in relationship'.
        'Widow': 'Not in relationship',
        'Alone': 'Not in relationship',
        'Absurd': 'Not in relationship',
        'YOLO': 'Not in relationship'
   data['Relationship_Status'] = data['Marital_Status'].map(marital)
data['Total Children'] = data['Kidhome'] + data['Teenhome']
        if x['Relationship Status'] == 'Not in relationship':
           result = 1 + x['Teenhome'] + x['Kidhome']
       elif x['Relationship Status'] == 'In relationship':
           result = 2 + x['Teenhome'] + x['Kidhome']
        return result
   data['Family Size'] = data.apply(fam size, axis=1)
```

Beberapa feature baru yang diextract dari feature-feature sebelumnya seperti Relationship_Status, Family_Size, Customer_Lifespan, Year, Total_Purchase, Total_Spending, Total_Offers, dan lainnya. (lihat full di source code)

```
# membuat feature baru berdasarkan tanggal bergabung dan diasumsikan data dikumpulkan pada awal juli 2014
data['Customer_Lifespan'] = (pd.to_datetime('2014-07-01') - data['Dt_Customer']).dt.days

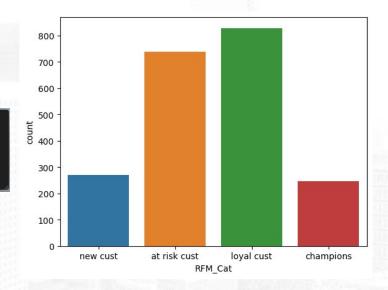
# ekstraksi feature Datetime menjadi feature baru
data['Year'] = data['Dt_Customer'].dt.year
data.drop(['Dt_Customer'],axis=1,inplace=True)

# membuat feature baru total purchase, total spending, dan total offers
data['Total_Purchase'] = data.apply(lambda x: x[purchase_cols[:-1]].sum(), axis=1)
data['Total_Offers'] = data.apply(lambda x: x[campaign_cols].sum(), axis=1)
```

Rakamin

A. Feature Extractions - RFM

```
# membuat feature baru category rfm score (champions, loyal, at risk, new)
   rfm['Recency'] = data['Recency']
  rfm['Frequency'] = data['Total Purchase']
  rfm['Monetary'] = data['Total Spending']
# kalkulasi score berdasarkan quantile masing-masing feature
2 rfm['recency score'] = pd.qcut(rfm['Recency'], q=[0, 0.25, 0.5, 0.75, 1], labels=[4, 3, 2, 1])
  rfm['frequency score'] = pd.qcut(rfm['Frequency'], q=[0, 0.25, 0.5, 0.75, 1], labels=[1, 2, 3, 4])
4 rfm['monetary score'] = pd.qcut(rfm['Monetary'], q=[0, 0.25, 0.5, 0.75, 1], labels=[1, 2, 3, 4])
            Recency Score
                                             Frequency Score
                                                                               Monetary Score
800
                                  800
                                  600
```



Melakukan segmentasi customer dengan menggunakan metode rfm. Customer dibagi menjadi 4 segment, yaitu champions, loyal, at risk, dan new customer. Berdasarkan count plot diketahui bahwa loyal customer paling banyak, champions adalah yang paling sedikit pada dataset. Lalu hasilnya digabungkan dengan dataset utama.

B.Feature Encoding

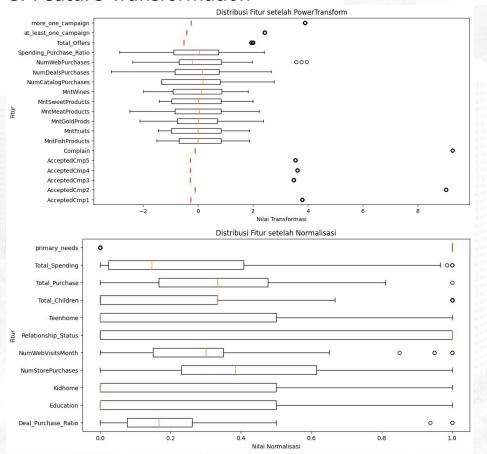
```
# encoding education
edu = {'Graduation': 1, 'Master': 2, 'PhD': 3}
oe edu = OrdinalEncoder(categories=[list(edu.keys())])
data['Education'] = oe edu.fit transform(data[['Education']])
# encoding marital_status
marital mapping = {'Single': 1, 'Married': 2, 'Divorced': 3}
data['Marital Status'] = data['Marital Status'].map(marital mapping)
# encoding relationship_status
rel mapping = {'Not in relationship': 0,
               'In relationship': 1}
data['Relationship_Status'] = data['Relationship_Status'].map(
    rel_mapping)
# encoding primary_needs
pr_mapping = {'primary_needs': 0,
              'secondary needs': 1}
data['primary_needs'] = data['primary_needs'].map(pr_mapping)
# encoding rfm cat
rfm_mapping = {'new cust': 1, 'at risk cust': 2,
               'loval cust': 3, 'champions': 4}
oe_rfm = OrdinalEncoder(categories=[li(rfm_mapping.keys())])
data['RFM Cat'] = oe rfm.fit transform(data[['RFM Cat']])
```



Menggunakan Ordinal encoder untuk mengubah categorical feature menjadi nilai ordinal. Beberapa feature yang dilakukan encode seperti education, marital_status, relationship_status, primary_needs, dan rfm_cat

Rakamin

C. Feature Transformation



Pada dataset ini melakukan 2 jenis transformasi yaitu normalisasi dan log transformasi/power transformasi.

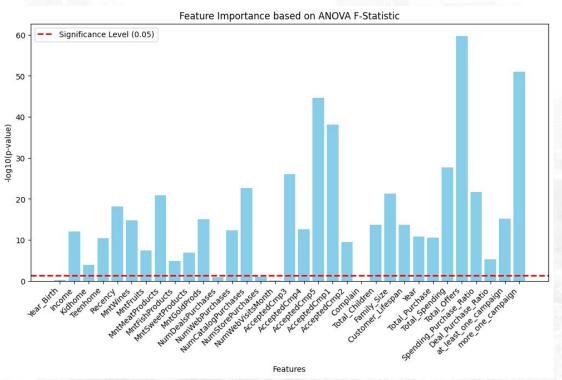
Normalisasi digunakan pada saat: mean < median < mode.

Transformasi digunakan pada saat: nilai skew_val <= -1 atau skew_val >= 1.

Library yang digunakan adalah MinMaxScaler untuk normalisasi dan PowerTransformer untuk yang transformasi log.

Rakamin

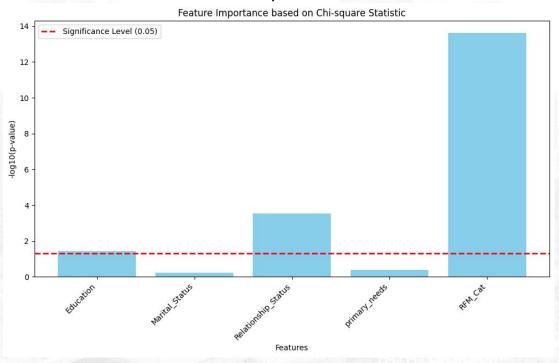
D. Feature Selection - ANOVA



Melakukan feature selection pada numerical feature dengan menggunakan metode anova, dan hasilnya didapatkan bahwa Year Birth, Num Deals Purchase, Num Web Visits Month, Num Store Purchases, Complain, tidak mampu melewati threshold p value < 0.05.

Rakamin

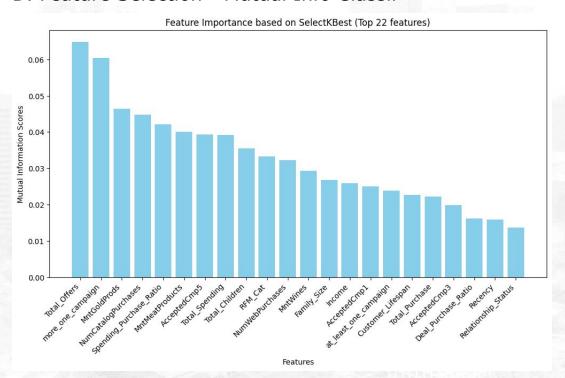
D. Feature Selection - Chi Square



Melakukan feature selection pada categorical feature dengan menggunakan metode chi-square, dan hasilnya didapatkan bahwa Marital Status dan primary needs tidak mampu melewati threshold p value < 0.05.

Rakamin

D. Feature Selection - Mutual Info Classif



Setelah menggabungkan feature selection dari metode anova dan chi2, selanjutnya menggunakan kbest dan mutual info classification. Dan didapatkan jumlah k yang terbaik adalah 22 feature. Dimana total offers merupakan feature dengan score tertinggi, sedangkan relationship status adalah yang terendah. Selanjutkan melakukan pengecekan multicollinearity menggunakan metode VIF.

more_one_campaign 1.854052e+06

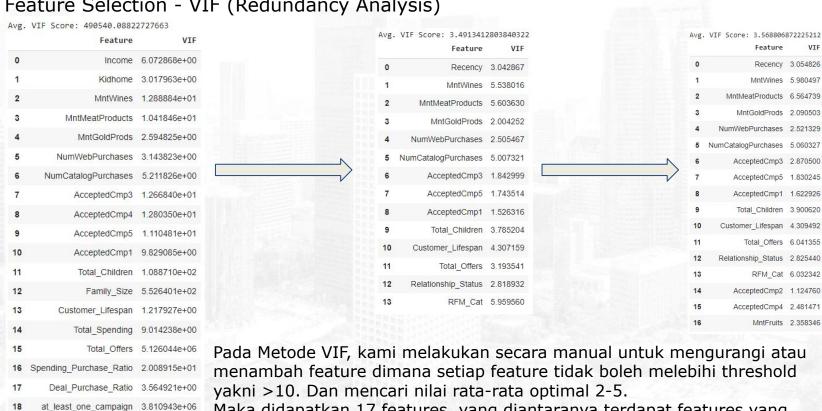
Relationship_Status 5.471427e+01

RFM Cat 2.922084e+00

19



D. Feature Selection - VIF (Redundancy Analysis)



Maka didapatkan 17 features, yang diantaranya terdapat features yang

dihasilkan dari extraction seperti RFM Cat, Total Offers, Relationship Status, dan Total Children.

E. Feature Imbalance

```
# melakukan imbalace handling pada target
from imblearn.over_sampling import SMOTE

# menampikan jumlah kelas sebelum oversampling
print("Jumlah kelas sebelum oversampling:")
print("Kelas 0:", sum(y_train == 0))
print("Kelas 1:", sum(y_train == 1))

# melakukan oversampling dengan SMOTE
smote = SMOTE(random_state=42)
X_resampled, y_resampled = smote.fit_resample(X_train, y_train)

# menampilkan jumlah kelas setelah oversampling
print("\nJumlah kelas setelah oversampling:")
print("Kelas 0:", sum(y_resampled == 0))
print("Kelas 1:", sum(y_resampled == 1))
```

```
Jumlah kelas sebelum oversampling:
Kelas 0: 1397
Kelas 1: 251

Jumlah kelas setelah oversampling:
Kelas 0: 1397
Kelas 1: 1397
```



Menggunakan metode oversampling pada library SMOTE. Dimana feature target dengan values 1, awalnya berjumlah 251 menjadi 1397.

5. GIT



https://github.com/hilmanman92/market-insider/tree/staging

